Probabilités

Table des matières

1. Cadre général de la théorie des probabilités

1.1. Espace probabilisé général

Définition 1.1. Soit Ω un ensemble. On appelle *tribu* sur Ω une famille $\mathcal{F}$ de parties de Ω vérifiant :
(1) $\mathcal{F}$ est non-vide : $\varnothing \in \mathcal{F}$,
(2) la stabilité par passage au complémentaire : $\forall A \in \mathcal{F}, A^c \in \mathcal{F}$,
(3) la stabilité par union dénombrable : $\forall (A_n)_{n\in\mathbb{N}} \in \mathcal{F}^{\mathbb{N}}, \bigcup_{n\geq 1} A_n \in \mathcal{F}$.

Définition 1.2. Soit Ω un ensemble et $\mathcal{F}$ une tribu sur Ω. On appelle *mesure de probabilité* une mesure $\mathbb{P} : \mathcal{F} \to \mathbb{R}_+$ vérifiant $\mathbb{P}(\Omega) = 1$.

Définition 1.3. Soit Ω un ensemble, $\mathcal{F}$ une tribu sur Ω et $\mathbb{P}$ une mesure de probabilité sur $(\Omega, \mathcal{F})$. On appelle *espace probabilisé* le triplet $(\Omega, \mathcal{F}, \mathbb{P})$, on dit que Ω est *l'univers* et que $\mathcal{F}$ sont *les événements*.

Remarque 1.4. Dans le cadre discret, on avait souvent $\mathcal{F} \coloneqq \mathcal{P}(\Omega)$. Dans le cadre général, on aura souvent $\mathcal{F} \subsetneq \mathcal{P}(\Omega)$.

Définition 1.5. Soit $(A_n)_{n\in\mathbb{N}}$ une suite d'événements sur $(\Omega, \mathcal{F}, \mathbb{P})$. On dit que $(A_n)_{n\in\mathbb{N}}$ est un *système complet* si elle vérifie :
(1) les A_n sont disjoints deux à deux : $\forall i, j \in \mathbb{N}, i \neq j \Rightarrow A_i \neq A_j$,
(2) la probabilité de l'union des A_n est 1 : $\mathbb{P}\left(\bigcup_{n\in\mathbb{N}} A_n\right) = 1$.

Proposition 1.6. Soit $(A_n)_{n\in\mathbb{N}}$ un système complet sur $(\Omega, \mathcal{F}, \mathbb{P})$. Alors on a

$$\forall B \in \mathcal{F}, \mathbb{P}(B) = \sum_{n=1}^{+\infty} \mathbb{P}(B \cap A_n).$$

Démonstration. On pose $C \coloneqq \bigcup_{n\geq 1} A_n$, puisque $\mathbb{P}(C) = 1$, on a $\mathbb{P}(C^c) = 0$ d'où $\mathbb{P}(B \cap C^c) = 0$. Soit $B \in \mathcal{F}$, on en déduit

$$\mathbb{P}(B) = \mathbb{P}(B \cap C) + \underbrace{\mathbb{P}(B \cap C^c)}_{=0} = \mathbb{P}\left(\bigcup_{n\geq 1} B \cap A_n\right) = \sum_{n=1}^{+\infty} \mathbb{P}(B \cap A_n).$$

$\square$

Corollaire 1.7. Soit $(A_n)_{n\in\mathbb{N}}$ un système complet sur $(\Omega, \mathcal{F}, \mathbb{P})$. Alors pour tout $B \in \mathcal{F}$on a
(1) $\mathbb{P}(B) = \sum_{n=1}^{+\infty} \mathbb{P}(A_n) P(B|A_n)$,
(2) $\forall i \geq 1, \mathbb{P}(A_i|B) = \dfrac{\mathbb{P}(A_i)\mathbb{P}(B|A_i)}{\sum_{n=1}^{+\infty} \mathbb{P}(A_n)\mathbb{P}(B|A_n)}$.

Théorème 1.8. (Continuité de la mesure de probabilité) Soit $(\Omega, \mathcal{F}, \mathbb{P})$ un espace probabilisé.
(1) Soit $(A_n)_{n\in\mathbb{N}}$ une suite croissante d'événements. Alors on a

$$\lim_{n\to+\infty} \mathbb{P}(A_n) = \mathbb{P}\left(\bigcup_{n\geq 1} A_n\right).$$

(2) Soit $(A_n)_{n\in\mathbb{N}}$ une suite décroissante d'événements. Alors on a

$$\lim_{n\to+\infty} \mathbb{P}(A_n) = \mathbb{P}\left(\bigcap_{n\geq 1} A_n\right).$$

Démonstration.
(1) Pour tout $n \geq 1$, on pose $B_n \coloneqq A_n \setminus A_{n-1}$ avec $A_0 = \varnothing$, tel que les $(B_n)_{n\in\mathbb{N}}$ forme un système complet sur $\bigcup_{n\geq 1} A_n$, on en déduit alors

$$\mathbb{P}\left(\bigcup_{n\geq 1} A_n\right) = \mathbb{P}\left(\bigcup_{n\geq 1} B_n\right) = \sum_{n=1}^{+\infty} \mathbb{P}(B_n) = \sum_{n=1}^{+\infty} \mathbb{P}(A_n) - \mathbb{P}(A_{n-1})$$

on reconnait une somme téléscopique et on a donc

$$\mathbb{P}\left(\bigcup_{n\geq 1} A_n\right) = \lim_{n\to+\infty} \mathbb{P}(A_n) - \mathbb{P}(A_0) = \lim_{n\to+\infty} \mathbb{P}(A_n).$$

(2) On obtient directement le résultat par passage au complémentaire.

$\square$

Définition 1.9. Soit $(A_n)_{n\in\mathbb{N}}$ une suite d'événements de $(\Omega, \mathcal{F}, \mathbb{P})$.

- On appelle *limite supérieure* de la suite $(A_n)_{n\in\mathbb{N}}$ la valeur

$$\limsup_{n\to+\infty} A_n := \bigcap_{n\geq 1} \bigcup_{k\geq n} A_k$$

intuitivement on considère les éléments qui appartiennent à une infinité d'événements.

- On appelle *limite inférieure* de la suite $(A_n)_{n\in\mathbb{N}}$ la valeur

$$\limsup_{n\to+\infty} A_n := \bigcup_{n\geq 1} \bigcap_{k\geq n} A_k.$$

Corollaire 1.10. Soit $(A_n)_{n\in\mathbb{N}}$ une suite d'événements de $(\Omega, \mathcal{F}, \mathbb{P})$. Alors on a

$$\mathbb{P}\left(\limsup_{n\to+\infty} A_n\right) = \lim_{m\to+\infty} \lim_{n\to+\infty} \mathbb{P}\left(\bigcup_{k=m}^{n} A_k\right)$$
$$\mathbb{P}\left(\liminf_{n\to+\infty} A_n\right) = \lim_{m\to+\infty} \lim_{n\to+\infty} \mathbb{P}\left(\bigcap_{k=m}^{n} A_k\right)$$

Proposition 1.11. Soit $(A_n)_{n\in\mathbb{N}}$ une suite d'événements de $(\Omega, \mathcal{F}, \mathbb{P})$. Alors on a

$$\mathbb{P}\left(\bigcup_{n\geq 1} A_n\right) \leq \sum_{n=1}^{+\infty} A_n.$$

Démonstration. On sait que le résultat est vérifié pour un nombre fini d'événements. Par passage à la limite et par continuité de la mesure $\mathbb{P}$ on a

$$\mathbb{P}\left(\bigcup_{n\geq 1} A_n\right) = \lim_{m\to+\infty} \mathbb{P}\left(\bigcup_{n=1}^{m} A_n\right) \leq \lim_{m\to+\infty} \sum_{n=1}^{m} \mathbb{P}(A_n) = \sum_{n=1}^{+\infty} \mathbb{P}(A_n).$$

$\square$

Définition 1.12. Soit A un événement de $(\Omega, \mathcal{F}, \mathbb{P})$.

- On dit que A est *négligeable* si $\mathbb{P}(A) = 0$.
- On dit que A est *presque-sûr* si $\mathbb{P}(A) = 1$.

Corollaire 1.13. Soit $(\Omega, \mathcal{F}, \mathbb{P})$ un espace probabilisé. Alors

- L'union dénombrable d'événements négligeables est négligeable.
- L'intersection dénombrable d'événements presque-sûrs est presque-sûre.

Proposition 1.14. Soit $\mathcal{A}$ une famille d'événements de $(\Omega, \mathcal{F}, \mathbb{P})$. Alors il existe une unique tribu $\sigma(\mathcal{A})$ telle que $\sigma(\mathcal{A})$ soit la plus petite tribu contenant $\mathcal{A}$.

Démonstration. Il existe au moins une tribu contenant $\mathcal{A}$, à savoir $\mathcal{P}(\Omega)$. Alors l'intersection de toutes les tribus contenant $\mathcal{A}$ est une tribu et convient. $\square$

Définition 1.15. Soit $\mathcal{A}$ une famille d'événements de $(\Omega, \mathcal{F}, \mathbb{P})$. On appelle *tribu engendrée* par $\mathcal{A}$, notée $\sigma(\mathcal{A})$, la tribu de la Proposition 1.14.

Exemple 1.16. Soit A un événement de $(\Omega, \mathcal{F}, \mathbb{P})$. Alors $\sigma(\{A\}) = \{\varnothing, A, A^c, \Omega\}$.

1.2. Exemples d'espace probabilisés

Définition 1.17. Soit $(E, \mathcal{O})$ un espace topologique. On appelle *tribu borélienne* sur E, notée $\mathcal{B}(E)$, la tribu engendrée par les intervalles ouverts de E, c'est-à-dire $\mathcal{B}(E) \coloneqq \sigma(\mathcal{O})$.

Lemme 1.18. Soit $(\mu_n)_{n\in\mathbb{N}}$ une suite de mesures de probabilité sur $(\Omega, \mathcal{F})$ et $(\lambda_n)_{n\in\mathbb{N}}$ une suite de nombres réels positifs telle que $\sum_{n=1}^{+\infty} \lambda_n = 1$. Alors $\mu = \sum_{n=1}^{+\infty} \lambda_n \mu_n$ est une mesure de probabilité sur $(\Omega, \mathcal{F})$.

1.2.1. Univers $\Omega = \mathbb{N}$

Se référer au cours de *Probabilités* de deuxième année.

1.2.2. Univers $\Omega = \mathbb{R}$

Exemple 1.19. (Mesure de Dirac) Soit $x \in \mathbb{R}$, l'application $\delta_x : \mathcal{B}(\mathbb{R}) \to \mathbb{R}_+$ définie par

$$\forall A \in \mathcal{B}(\mathbb{R}), \delta_x(A) = \begin{cases} 0 \text{ si } x \notin A \\ 1 \text{ si } x \in A \end{cases}$$

est une mesure de probabilité sur $\mathbb{R}$.

Exemple 1.20. (Mesure uniforme sur $\{1, \ldots, n\}$) L'application $\mu = \frac{1}{n} \sum_{k=1}^{n} \delta_k$ est une mesure uniforme sur $\mathbb{R}$.

Exemple 1.21. (Mesure de Poisson) Soit $\lambda > 0$, l'application $\mu = \sum_{n=1}^{+\infty} e^{-\lambda} \frac{\lambda^n}{n!} \delta_n$ est une mesure de Poisson sur $\mathbb{R}$.

Définition 1.22. Soit $f : \mathbb{R} \to \mathbb{R}$ une fonction borélienne. On dit que f est une *densité de probabilité* sur $\mathbb{R}$ si elle vérifie :
(1) pour λ-presque tout $x \in \mathbb{R}, f(x) \geq 0$,
(2) $\int_{\mathbb{R}} f(x) \,\mathrm{d}\lambda(x) = 1$.

Lemme 1.23. Soit f une densité de probabilité sur $\mathbb{R}$. Alors l'application $\mu_f : \mathcal{B}(\mathbb{R}) \to \mathbb{R}_+$ définie par $\forall A \in \mathcal{B}(\mathbb{R}), \mu_f(A) = \int_A f(x) \,\mathrm{d}\lambda(x)$ est une mesure de probabilité sur $\mathbb{R}$.

Démonstration. On a bien $\forall A \in \mathcal{B}(\mathbb{R}), \mu_f(A) \geq 0$. De plus $\mu_f(\mathbb{R}) = 1$. Soit $(A_n)_{n\in\mathbb{N}}$ une suite d'éléments de $\mathcal{B}(\mathbb{R})$ deux à deux disjoints. On pose $A \coloneqq \bigcup_{n\geq 1} A_n$, alors $\mathbb{1}_A = \sum_{n=1}^{+\infty} \mathbb{1}_{A_n}$ et

$$\mu_f(A) = \int_A f(x) \,\mathrm{d}\lambda(x) = \int_{\mathbb{R}} \mathbb{1}_A(x) f(x) \,\mathrm{d}\lambda(x) = \int_{\mathbb{R}} \sum_{n=1}^{+\infty} \mathbb{1}_{A_n}(x) f(x) \,\mathrm{d}\lambda(x)$$

d'après le théorème de convergence monotone on a

$$\mu_f(A) = \lim_{m\to+\infty} \int_{\mathbb{R}} \sum_{n=1}^{m} \mathbb{1}_{A_n} f(x) \,\mathrm{d}\lambda(x) = \lim_{m\to+\infty} \sum_{n=1}^{m} \mu_f(A_n) = \sum_{n=1}^{+\infty} \mu_f(A_n).$$

Donc μ_f est bien une mesure de probabilité sur $\mathbb{R}$. $\square$

Remarque 1.24. On dit que μ_f est la *mesure de densité* f.

Proposition 1.25. Soit f et g deux densités de probabilités sur $\mathbb{R}$. Alors les mesures de densité μ_f et μ_g sont égales si et seulement si f et g sont égales presque partout.

Démonstration.
$\Rightarrow$: Supposons que $\mu_f = \mu_g$. On pose

$$A_+ \coloneqq \{x \in \mathbb{R} \mid f(x) > g(x)\}$$
$$A_- \coloneqq \{x \in \mathbb{R} \mid f(x) < g(x)\}$$

ces deux ensembles sont boréliens car f et g sont boréliennes. Par construction

$$\int_{A_+} f - g \,\mathrm{d}\lambda = \mu_f(A_+) - \mu_g(A_+) = 0 = \int_{A_-} f - g \,\mathrm{d}\lambda$$

de plus $A \coloneqq \{x \in \mathbb{R} \mid |f(x) - g(x)| > 0\} = A_+ \cup A_-$, on en déduit

$$\int_A |f - g| \,\mathrm{d}\lambda = \int_A (f - g)\mathbb{1}_{A_+} + (g - f)\mathbb{1}_{A_-} \,\mathrm{d}\lambda = 0$$

donc $f - g = 0$ presque partout et $f = g$ presque partout.

$\Leftarrow$: Si $f = g$ presque partout, alors il est évident que $\mu_f = \mu_g$. $\square$

Exemple 1.26. (Loi uniforme) Soit $c, d \in \mathbb{R}$ avec $c < d$. Alors la fonction $f : \mathbb{R} \to \mathbb{R}; x \mapsto \frac{\mathbb{1}_{[c,d]}(x)}{d-c}$ est une densité de probabilité. En particulier, pour tout $[a, b] \subset [c, d]$

$$\mu_f([a, b]) = \int_{[a,b]} f(x) \,\mathrm{d}\lambda(x) = \frac{b - a}{d - c}.$$

On note la probabilité associée $\mathcal{U}([c, d])$.

Exemple 1.27. (Loi exponentielle) Soit $\lambda > 0$. Alors la fonction $f : \mathbb{R} \to \mathbb{R}; x \mapsto \lambda e^{-\lambda x}\mathbb{1}_{\mathbb{R}_+}(x)$ est une densité de probabilité. On note la probabilité associée $\mathcal{E}(\lambda)$.

Exemple 1.28. (Loi normale) La fonction $f : \mathbb{R} \to \mathbb{R}; x \mapsto \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}$ est une densité de probabilité. On note la probabilité associée $\mathcal{N}(0, 1)$.

1.2.3. Univers $\Omega = \mathbb{R}^d$

On peut étendre les exemples de $\mathbb{R}$, ainsi que les définitions de densité et de mesures de probabilité associée.

1.3. Classe monotone

Définition 1.29. Soit $\mathcal{C}$ une famille de parties d'un ensemble Ω. On dit que $\mathcal{C}$ est une *classe monotone* si elle vérifie :
(1) $\Omega \in \mathcal{C}$,
(2) $\forall A, B \in \mathcal{C}, A \subset B \Rightarrow B \setminus A \in \mathcal{C}$,
(3) $\forall (A_n)_{n\in\mathbb{N}} \in \mathcal{C}^{\mathbb{N}}$ croissante, $\bigcup_{n\in\mathbb{N}} A_n \in \mathcal{C}$.

Remarque 1.30. Une tribu est une classe monotone, la réciproque est fausse.

Lemme 1.31. Soit $\mathcal{C}$ une classe monotone. Alors $\mathcal{C}$ est une tribu si et seulement si elle est stable par intersection finie, c'est-à-dire :

$$\forall A_1, ..., A_n \in \mathcal{C}, \bigcap_{k=1}^{n} A_n \in \mathcal{C}.$$

Démonstration.
$\Rightarrow$: Si $\mathcal{C}$ est une tribu elle est stable par intersection finie.
$\Leftarrow$: Supposons que $\mathcal{C}$ est stable par intersection finie. Soit $(A_n)_{n\in\mathbb{N}}$ une suite d'éléments de $\mathcal{C}$. Puisque $\mathcal{C}$ est stable par passage au complémentaire, $\mathcal{C}$ est aussi stable par union finie, en effet

$$A, B, \in \mathcal{C} \Rightarrow A^c, B^c \in \mathcal{C} \Rightarrow A^c \cap B^c \in \mathcal{C} \Rightarrow A \cup B = (A^c \cap B^c)^c \in \mathcal{C}$$

on a donc pour tout $N \in \mathbb{N}$, $\bigcup_{n=0}^{N} A_n \in \mathcal{C}$, et par union croissante

$$\bigcup_{n\in\mathbb{N}} A_n = \bigcup_{N\in\mathbb{N}} \underbrace{\bigcup_{n=0}^{N} A_n}_{\text{croissante}} \in \mathcal{C}$$

donc $\mathcal{C}$ est bien une tribu. □

Définition 1.32. Soit $\mathcal{A}$ une famille de parties d'un ensemble Ω. On appelle *classe monotone engendrée* par $\mathcal{A}$, notée $\mathcal{C}(\mathcal{A})$, l'intersection de toutes les classes monotones contenant $\mathcal{A}$.

Théorème 1.33. (Théorème de la classe monotone) Soit $\mathcal{A}$ une famille de partie d'un ensemble Ω. Si $\mathcal{A}$ est stable par intersection finie, alors $\mathcal{C}(\mathcal{A}) = \sigma(\mathcal{A})$.

Démonstration. Soit $A \in \mathcal{C}(\mathcal{A})$, on pose $\mathcal{C}_A \coloneqq \{B \in \mathcal{C}(\mathcal{A}) \mid A \cap B \in \mathcal{C}(\mathcal{A})\}$. Puisque $\mathcal{C}_A$ est une classe monotone contenant A, on a $\mathcal{C}_A = \mathcal{C}(\mathcal{A})$. Donc $\mathcal{C}(\mathcal{A})$ est stable par intersection finie. D'après le Lemme 1.31 $\mathcal{C}(\mathcal{A})$ est une tribu. □

Corollaire 1.34. Soit μ et ν deux mesures de probabilités sur $(\Omega, \mathcal{F})$. S'il existe une famille de parties $\mathcal{A}$ stable par intersection finie sur laquelle μ et ν coïncident, alors elles coïncident sur $\sigma(\mathcal{A})$.

1.4. Variables et vecteurs aléatoires

Définition 1.35. Soit $(\Omega, \mathcal{F})$ un espace probabilisable. On appelle *vecteur aléatoire* une application borélienne $X : (\Omega, \mathcal{F}) \to \big(\mathbb{R}^d, \mathcal{B}(\mathbb{R}^d)\big)$. Dans le cas $d = 1$, on dit que X est une *variable aléatoire*.

Proposition 1.36. Soit $(\Omega, \mathcal{F})$ un espace probabilisable.
(1) Une application $X : \Omega \to \mathbb{R}$ est une variable aléatoire si et seulement si

$$\forall t \in \mathbb{R}, X^{-1}(]-\infty, t]) \in \mathcal{F}$$

(2) Une application $X = (X_1, \dots, X_d) : \Omega \to \mathbb{R}^d$ est un vecteur aléatoire si et seulement si $X_1, \dots, X_d$ sont des variables aléatoires.
(3) Soit $X : \Omega \to \mathbb{R}^d$ un vecteur aléatoire et $\varphi : \mathbb{R}^d \to \mathbb{R}^n$ une application borélienne. Alors $\varphi \circ X$ est un vecteur aléatoire.

Démonstration.
(1) $\Rightarrow$: Si X est une variable aléatoire, alors X est mesurable et le résultat est évident.
$\Leftarrow$: Si pour tout $t \in \mathbb{R}$ on a $X^{-1}(]-\infty, t]) \in \mathcal{F}$. Alors puisque la famille $\{]-\infty, t] \mid t \in \mathbb{R}\}$ engendre $\mathcal{B}(\mathbb{R})$, X est mesurable. Donc X est une variable aléatoire.
(2) On obtient le résultat par projection en appliquant (1) à $X_1, \dots, X_n$.
(3) On obtient le résultat par composition de fonctions boréliennes.

□

Proposition 1.37. Soit $(X_n)_{n\in\mathbb{N}}$ une suite de variables aléatoires sur $(\Omega, \mathcal{F})$.
(1) Si les applications $S \coloneqq \sup_{n\in\mathbb{N}} X_n$ et $I \coloneqq \inf_{n\in\mathbb{N}} X_n$ sont finies, alors S et I sont des variables aléatoires.
(2) Si $(X_n)_{n\in\mathbb{N}}$ converge simplement vers une limite finie X, alors X est une variable aléatoire.

Démonstration.

(1) On remarque que pour tout $t \in \mathbb{R}$ on a $S^{-1}(]-\infty,t]) = \bigcap_{n\in\mathbb{N}} X^{-1}(]-\infty,t])$ et que l'on peut écrire de la même manière pour I.
(2) On remarque que $X = \lim_{n\to+\infty} X_n = \limsup_{n\to+\infty} X_n = \inf_{m\to+\infty}\left(\sup_{n\geq m} X_n\right)$.

□

1.4.1. Loi d'un vecteur aléatoire

Proposition 1.38. Soit $(\Omega,\mathcal{F},\mathbb{P})$ un espace probabilisé et $X : \Omega \to \mathbb{R}^d$ un vecteur aléatoire. Alors l'application $\mathbb{P}_X : \mathcal{B}(\mathbb{R}^d) \to \mathbb{R}_+; A \mapsto \mathbb{P}(X \in A) = \mathbb{P}(X^{-1}(A))$ est une mesure de probabilité sur $\mathbb{R}^d$.

Définition 1.39. Soit $(\Omega,\mathcal{F},\mathbb{P})$ un espace probabilisé et $X : \Omega \to \mathbb{R}^d$ un vecteur aléatoire. On appelle *loi de* X, notée $\mathbb{P}_X$, la mesure de probabilité de la Proposition 1.38. On dit aussi que X suit la loi $\mathbb{P}_X$.

Définition 1.40. Soit $(\Omega,\mathcal{F},\mathbb{P})$ un espace probabilisé et $X : \Omega \to \mathbb{R}^d$ un vecteur aléatoire. On appelle *atomes de* X, noté $\mathcal{V}_X$, l'ensemble

$$\mathcal{V}_X \coloneqq \left\{x \in \mathbb{R}^d \mid \mathbb{P}_X(\{x\}) > 0\right\}.$$

Exemple 1.41. (Loi de Bernoulli) On considère $(\Omega,\mathcal{F},\mathbb{P})$ avec $\Omega = \mathbb{R}$, $\mathcal{F} = \mathcal{B}(\mathbb{R})$ et $\mathbb{P}$ la mesure uniforme sur $[0,1]$. On prend $X = \mathbb{1}_{[0,p]}$ avec $p \in [0,1]$. Soit $A \in \mathcal{B}(\mathbb{R})$, alors

$$\begin{aligned}\mathbb{P}_X(A) &= \mathbb{P}(X^{-1}(A)) = \mathbb{P}(X^{-1}(A\cap\{0\})) + \mathbb{P}(X^{-1}(A\cap\{1\}))\\ &= \delta_0(A)\mathbb{P}(X^{-1}(0)) + \delta_1(A)\mathbb{P}(X^{-1}(1)) = \delta_0(A)(1-p) + \delta_1(A)p\end{aligned}$$

donc $\mathbb{P}_X = \delta_0(1-p) + \delta_1 p$.

Proposition 1.42. Soit $(\Omega,\mathcal{F},\mathbb{P})$ un espace probabilisé et $X = (X_1,\ldots,X_d) : \Omega \to \mathbb{R}^d$ un vecteur aléatoire. Si X admet une densité $f : \mathbb{R}^d \to \mathbb{R}_+$, alors les variables aléatoires $X_1,\ldots,X_d$ admettent des densités $f_1,\ldots,f_d : \mathbb{R} \to \mathbb{R}_+$ avec

$$\forall i \in \{1,\ldots,d\}, f_i(x) \coloneqq \int_{\mathbb{R}^{d-1}} f(x_1,\ldots,x_{i-1},x,x_{i+1},\ldots,x_d)\,\mathrm{d}\lambda(x_1,\ldots,x_{i-1},x_{i+1},\ldots,x_n).$$

Démonstration. Il suffit d'appliquer le théorème de Fubini. □

1.5. Fonction de répartition

Définition 1.43. Soit $\mathbb{P}$ une mesure de probabilité sur $(\mathbb{R},\mathcal{B}(\mathbb{R}))$. On appelle *fonction de répartition*, notée $F_\mathbb{P}$, la fonction $F_\mathbb{P} : \mathbb{R} \to \mathbb{R}_+; t \mapsto \mathbb{P}(]-\infty,t])$.

Définition 1.44. Soit $(\mathbb{R},\mathcal{B}(\mathbb{R}),\mathbb{P})$ un espace probabilisé, et X une variable aléatoire. On appelle *fonction de répartition de* X, notée F_X, la fonction de répartition liée à $\mathbb{P}_X$.

Proposition 1.45. Soit $(\mathbb{R},\mathcal{B}(\mathbb{R}),\mathbb{P})$ un espace probabilisé, et $X, Y : \mathbb{R} \to \mathbb{R}$ deux variables aléatoires. Alors X et Y ont la même loi si et seulement si elles ont la même fonction de répartition.

Démonstration.
$\Rightarrow$: Supposons que $\mathbb{P}_X = \mathbb{P}_Y$. Alors on a

$$\forall t \in \mathbb{R}, F_X(t) = \mathbb{P}_X(]-\infty,t]) = \mathbb{P}_Y(]-\infty,t]) = F_Y(t)$$

donc $F_X = F_Y$.

$\Leftarrow$: Supposons que $F_X = F_Y$. Alors on pose $\mathcal{A} \coloneqq \{]-\infty,t] \mid t \in \mathbb{R}\}$ qui est stable par intersection avec $\sigma(\mathcal{A}) = \mathcal{B}(\mathbb{R})$, on pose $\mathcal{C} \coloneqq \{A \in \mathcal{B}(\mathbb{R}) \mid P_X(A) = P_Y(A)\}$ qui est une classe monotone, alors d'après le théorème de la classe monotone $\mathcal{C} = \mathcal{B}(\mathbb{R})$. Donc $P_X = P_Y$ □

1.5.1. Reconnaitre une densité de probabilité

Proposition 1.46. Soit $(\mathbb{R}, \mathcal{B}(\mathbb{R}), \mathbb{P})$ un espace probabilisé et $X : \mathbb{R} \to \mathbb{R}$ une variable aléatoire. Alors si la fonction de répartition de X est C^1 par morceaux, X admet une densité de probabilité définie par $f = F_X'$ si F_X est dérivable et $f = 0$ sinon.

Démonstration. Puisque F_X est C^k par morceaux, il existe une suite croissante $(a_n)_{n\in\mathbb{Z}}$ telle que

$$\lim_{n\to+\infty} a_n = -\lim_{n\to-\infty} a_k = +\infty$$

et pour tout $n \in \mathbb{Z}$, F_X soit dérivable sur $]a_n, a_{n+1}[$. Soit $n \in \mathbb{Z}$, alors

$$\forall s,t \in]a_n, a_{n+1}[, \int_s^t f(x)\,\mathrm{d}x = F_X(t) - F_X(s)$$

et par passage à la limite pour $s \longrightarrow a_n$ et $t \longrightarrow a_{n+1}$ on a

$$\int_{a_n}^{a_{n+1}} f(x)\,\mathrm{d}x = F_X(a_n) - F_X(a_{n+1}).$$

Soit $t \in \mathbb{R}$, alors il existe $n \in \mathbb{Z}$ tel que $t \in]a_n, a_{n+1}[$ et

$$\int_{-\infty}^t f(x)\,\mathrm{d}x = \sum_{k=-\infty}^{n} \int_{a_n}^{a_{n+1}} f(x)\,\mathrm{d}x + \int_{a_n}^t f(x)\,\mathrm{d}x$$

on reconnait une somme téléscopique et on a donc

$$\int_{-\infty}^t f(x)\,\mathrm{d}x = F_X(t) - \underbrace{\lim_{k\to-\infty} F_X(a_k)}_{=0} = F_X(t) = \mathbb{P}_X(]-\infty, t]).$$

□

1.5.2. Reconnaitre une loi discrète

Définition 1.47. Soit $(\mathbb{R}, \mathcal{B}(\mathbb{R}), \mathbb{P})$ un espace probabilisé et $X : \mathbb{R} \to \mathbb{R}$ une variable aléatoire. On appelle *saut* de la fonction de répartition de X, noté Δ_X, la fonction définie par

$$\forall t \in \mathbb{R}, \Delta_X(t) \coloneqq F_X(t) - \lim_{x\to t^-} F_X(x).$$

Lemme 1.48. Soit $(\mathbb{R}, \mathcal{B}(\mathbb{R}), \mathbb{P})$ un espace probabilisé et $X : \mathbb{R} \to \mathbb{R}$ une variable aléatoire. Alors l'ensemble des points de discontinuités, noté $\mathcal{D}_X \coloneqq \{t \in \mathbb{R} \mid \Delta_X(t) > 0\}$, est dénombrable avec $\sum_{t\in\mathcal{D}_X} \Delta_X(t) \leq 1$ de plus X est discrète si et seulement si $\sum_{t\in\mathcal{D}_X} \Delta_X(t) = 1$.

2. Espérance

2.1. Calculs de l'espérance

2.1.1. Définition et formule de transfert

Définition 2.1. Soit $(\Omega, \mathcal{F}, \mathbb{P})$ un espace probabilisable et $X : \Omega \to \mathbb{R}_d$ un vecteur aléatoire. On appelle *espérance* de X, notée $\mathbb{E}[X]$, la valeur

$$\mathbb{E}[X] \coloneqq \int_\Omega X(\omega) \,\mathrm{d}\mathbb{P}(\omega) = \int_{\mathbb{R}^d} x \,\mathrm{d}\mathbb{P}_X(x).$$

Remarque 2.2. Pour que l'intégrale précédente ait du sens dans $\mathbb{R}$ on a besoin que :
- $X \geq 0$ presque sûrement,
- X soit intégrable sur $(\Omega, \mathcal{F}, \mathbb{P})$.

Théorème 2.3. (Formule de transfert) Soit $(\Omega, \mathcal{F}, \mathbb{P})$ un espace probabilisable, $X : \Omega \to \mathbb{R}_d$ un vecteur aléatoire et $\varphi : \mathbb{R}^d \to \mathbb{R}_+ \cup \{+\infty\}$ une application mesurable. Alors

$$\mathbb{E}[\varphi(X)] = \int_\Omega \varphi(X(\omega)) \,\mathrm{d}\mathbb{P}(\omega) = \int_{\mathbb{R}^d} \varphi(x) \,\mathrm{d}\mathbb{P}_X(x).$$

Remarque 2.4. Pour que l'intégrale précédente ait du sens on a besoin que :
- $\varphi(X)$ soit intégrable sur $(\Omega, \mathcal{F}, \mathbb{P})$, c'est-à-dire que φ soit intégrable sur $\left(\mathbb{R}^d, \mathcal{B}\left(\mathbb{R}^d\right), \mathbb{P}_X\right)$.

Proposition 2.5. (Cas discret) Soit $(\Omega, \mathcal{F}, \mathbb{P})$ un espace probabilisable, $X : \Omega \to \mathbb{R}_d$ un vecteur aléatoire et $\varphi : \mathbb{R}^d \to \mathbb{R}_+ \cup \{+\infty\}$ une application mesurable. Alors

$$\mathbb{E}[\varphi(X)] = \sum_{\omega \in \mathcal{V}_X} \varphi(\omega) \mathbb{P}(X = \omega).$$

Proposition 2.6. (Cas à densité) Soit $(\Omega, \mathcal{F}, \mathbb{P})$ un espace probabilisable, $X : \Omega \to \mathbb{R}_d$ un vecteur aléatoire à densité $f : \mathbb{R}^d \to \mathbb{R}_+$ et $\varphi : \mathbb{R}^d \to \mathbb{R}_+ \cup \{+\infty\}$ une application mesurable. Alors

$$\mathbb{E}[\varphi(X)] = \int_{\mathbb{R}^d} \varphi(x) f(x) \,\mathrm{d}\lambda(x).$$

2.1.2. Variance

Définition 2.7. Soit $(\Omega, \mathcal{F}, \mathbb{P})$ un espace probabilisable et $X : \Omega \to \mathbb{R}_d$ un vecteur aléatoire. On appelle *variance* de X, notée $V(X)$, la valeur

$$V(X) \coloneqq \mathbb{E}\left[(X - \mathbb{E}[X])^2\right].$$

Proposition 2.8. Soit $(\Omega, \mathcal{F}, \mathbb{P})$ un espace probabilisable et $X : \Omega \to \mathbb{R}_d$ un vecteur aléatoire. Alors la variance de X vérifie les propriétés suivantes :
(1) $V(X)$ ne dépend que de X.
(2) $V(X) \geq 0$, avec égalité si et seulement si X est constante.
(3) $\forall a, b \in \mathbb{R}, V(aX + b) = a^2 V(X)$.
(4) $V(X) = \mathbb{E}\left[X^2\right] - \mathbb{E}[X]^2$.

2.1.3. Covariance

Définition 2.9. Soit $(\Omega, \mathcal{F}, \mathbb{P})$ un espace probabilisable et $X, Y : \Omega \to \mathbb{R}_d$ deux vecteurs aléatoires. On appelle *covariance* de X et X, notée $\mathrm{Cov}(X, Y)$, la valeur

$$\mathrm{Cov}(X, Y) \coloneqq \mathbb{E}[(X - \mathbb{E}[X])(Y - \mathbb{E}[Y])].$$

Proposition 2.10. Soit $(\Omega, \mathcal{F}, \mathbb{P})$ un espace probabilisable et $X, Y : \Omega \to \mathbb{R}_d$ deux vecteurs aléatoires. Alors la covariance vérifie les propriétés suivantes :
(1) Cov est bilinéaire symetrique.
(2) $\mathrm{Cov}(X,X) = V(X)$.
(3) $\mathrm{Cov}(X,Y) = \mathbb{E}[XY] - \mathbb{E}[X]\mathbb{E}[Y]$.
(4) $\mathrm{Cov}(X,Y) \leq \sqrt{V(X)V(Y)}$, avec égalité si et seulement si X et Y sont en relation affine.
(5) $V(X+Y) = V(X) + V(Y) + 2\,\mathrm{Cov}(X,Y)$.

2.1.4. Concentration

Définition 2.11. Soit $(\Omega, \mathcal{F}, \mathbb{P})$ un espace probabilisable et $X, Y : \Omega \to \mathbb{R}_d$ deux vecteurs aléatoires. Alors si $\mathrm{Cov}(X,Y) = 0$ on dit que X et Y sont *non correlées*.

Corollaire 2.12. Soit $(\Omega, \mathcal{F}, \mathbb{P})$ un espace probabilisable et $X, Y : \Omega \to \mathbb{R}_d$ deux vecteurs aléatoires. Alors si X et Y sont non-correlées, on a $V(X+Y) = V(X) + V(Y)$.

Définition 2.13. Soit $(\Omega, \mathcal{F}, \mathbb{P})$ un espace probabilisable et $X_1, \ldots, X_n : \Omega \to \mathbb{R}_d$ des vecteurs aléatoires. On appelle *moyenne empirique* de $X_1, \ldots, X_n$, notée $\overline{X}_n$, le vecteur aléatoire

$$\overline{X}_n \coloneqq \frac{1}{n} \sum_{k=1}^{n} X_k.$$

Proposition 2.14. Soit $(\Omega, \mathcal{F}, \mathbb{P})$ un espace probabilisable et $X_1, \ldots, X_n : \Omega \to \mathbb{R}_d$ des vecteurs aléatoires. Alors l'espérance de $\overline{X}_n$ est donnée par

$$\mathbb{E}\left[\overline{X}_n\right] = \frac{1}{n} \sum_{k=1}^{n} \mathbb{E}[X_k]$$

et sa variance par

$$V\left(\overline{X}_n\right) = \frac{1}{n^2} \sum_{k=1}^{n} V(X_k)$$

Proposition 2.15. (Inégalité de Markov et de Bienaymé-Chebychev) Soit $(\Omega, \mathcal{F}, \mathbb{P})$ un espace probabilisable et $X : \Omega \to \mathbb{R}$ une variable aléatoire.
(1) Si $X \geq 0$ presque sûrement, alors on a

$$\forall \varepsilon > 0, \mathbb{P}(X > \varepsilon) \leq \frac{\mathbb{E}[X]}{\varepsilon}.$$

(2) Si X est intégrable, alors on a

$$\forall \varepsilon > 0, \mathbb{P}(|X - \mathbb{E}[X]| > \varepsilon) \leq \frac{V(X)}{\varepsilon^2}.$$

Démonstration.
(1) Soit $\varepsilon > 0$, on remarque que l'on a toujours l'inégalité

$$\varepsilon \mathbb{1}_{\{X \geq \varepsilon\}} \leq X$$

par passage à l'espérance on trouve

$$\varepsilon \mathbb{E}\left[\mathbb{1}_{\{X \geq \varepsilon\}}\right] \leq \mathbb{E}[X]$$

ce qui donne bien l'inégalité de Markov.
(2) On applique l'inégalité de Markov à $(X - \mathbb{E}[X])^2$.

$\square$

Proposition 2.16. (Inégalité de Jensen) Soit $(\Omega, \mathcal{F}, \mathbb{P})$ un espace probabilisable, $X : \Omega \to \mathbb{R}$ une variable aléatoire intégrable et $\varphi : \mathbb{R} \to \mathbb{R}$ une fonction convexe bornée inférieurement. Alors

$$\varphi(\mathbb{E}[X]) \leq \mathbb{E}[\varphi(X)].$$

Théorème 2.17. (Inégalité de Hoeffding) Soit $(\Omega, \mathcal{F}, \mathbb{P})$ un espace probabilisable et $X_1, ..., X_n : \Omega \to \mathbb{R}$ des variables aléatoires indépendantes de sorte que pour tout $k \in \{1, ..., n\}$, il existe $a_k, b_k \in \mathbb{R}$ tels que $a_k \leq X_k \leq b_k$ presque sûrement. Si on note $S_n \coloneqq X_1 + ... + X_n$, alors

$$\forall t > 0, \max(\mathbb{P}(S_n - \mathbb{E}[S_n] \geq t), \mathbb{P}(S_n - \mathbb{E}[S_n] < t)) < \exp\left(-\frac{t^2}{\sum_{k=1}^{n} (b_k - a_k)^2}\right).$$

2.2. Application au calcul de lois

2.2.1. Méthode de la fonction muette

Proposition 2.18. (Méthode) Soit $(\Omega, \mathcal{F}, \mathbb{P})$ un espace probabilisable et $X : \Omega \to \mathbb{R}_d$ un vecteur aléatoire de densité $f : \mathbb{R}^d \to \mathbb{R}_+$. Alors pour toute fonction borélienne positive

$$\mathbb{E}[h(X)] = \int_{\mathbb{R}^d} h(x) f(x) \,\mathrm{d}\lambda(x)$$

en particulier pour tout $A \in \mathcal{F}$ en prenant $h \coloneqq \mathbb{1}_A$ on trouve

$$\mathbb{P}(X \in A) = \mathbb{E}[\mathbb{1}_A(X)] = \int_A f(x) \,\mathrm{d}\lambda(x).$$

ce qui montre que X est de densité f.

3. Indépendance

3.1. Vecteurs aléatoires indépendants

Définition 3.1. Soit $(\Omega, \mathcal{F}, \mathbb{P})$ un espace probabilisable et $X_1, \dots, X_n : \Omega \to \mathbb{R}^{d_i}$ des vecteurs aléatoires. On dit que $X_1, \dots, X_n$ sont *indépendants*, noté $X_1 \perp\!\!\!\perp \dots \perp\!\!\!\perp X_n$, si

$$\forall A_1, \dots, A_n \in \mathcal{B}\big(\mathbb{R}^{d_1}\big) \times \dots \times \mathcal{B}\big(\mathbb{R}^{d_n}\big), \mathbb{P}(X_1 \in A_1, \dots, X_n \in A_n) = \prod_{i=1}^{n} P(X_i \in A_i).$$

Lemme 3.2. Soit $(\Omega, \mathcal{F}, \mathbb{P})$ un espace probabilisable, et $X : \Omega \to \mathbb{R}^p$ et $Y : \Omega \to \mathbb{R}^q$ deux vecteurs aléatoires. Alors les assertions suivantes sont équivalentes :

(1) X et Y sont indépendants.
(2) $\mathbb{P}_{(X,Y)} = \mathbb{P}_X \otimes \mathbb{P}_Y$.
(3) Pour toutes fonctions boréliennes positives g et h, $\mathbb{E}[g(X)h(Y)] = \mathbb{E}[g(X)]\mathbb{E}[h(Y)]$

Démonstration.
(1) ⇒ (2) : Soit $A \in \mathcal{B}(\mathbb{R}^p)$ et $B \in \mathcal{B}(\mathbb{R}^q)$. Puisque X et Y sont indépendants on a

$$\begin{aligned}
\mathbb{P}_{(X,Y)}(A \times B) &= \mathbb{P}((X, Y) \in A \times B) \\
&= \mathbb{P}(X \in A, Y \in B) \\
&= \mathbb{P}(X \in A)\mathbb{P}(Y \in B) \\
&= \mathbb{P}_X(A)\mathbb{P}_Y(B) = (\mathbb{P}_X \otimes \mathbb{P}_Y)(A \times B)
\end{aligned}$$

par unicité de la mesure produit $\mathbb{P}_{(X,Y)} = \mathbb{P}_X \otimes \mathbb{P}_Y$.

(2) ⇒ (3) : Soit g et h deux fonctions boréliennes positives. Alors par la formule de transfert, en posant $\varphi : \mathbb{R}^p \times \mathbb{R}^q \to \mathbb{R}_+; (x, y) \mapsto g(x)h(y)$, on a

$$\begin{aligned}
\mathbb{E}[\varphi(X, Y)] &= \int_{\mathbb{R}^p \times \mathbb{R}^q} \varphi(x, y) \, \mathrm{d}\mathbb{P}_{(X,Y)}(x, y) \\
&= \int_{\mathbb{R}^p \times \mathbb{R}^q} g(x)h(y) \, \mathrm{d}(\mathbb{P}_X \otimes \mathbb{P}_Y)(x, y)
\end{aligned}$$

en appliquant Fubini, on trouve

$$\begin{aligned}
\mathbb{E}[\varphi(X, Y)] &= \int_{\mathbb{R}^q} \int_{\mathbb{R}^p} g(x)h(y) \, \mathrm{d}\mathbb{P}_X(x) \, \mathrm{d}\mathbb{P}_Y(y) \\
&= \int_{\mathbb{R}^q} h(y) \int_{\mathbb{R}^p} g(x) \, \mathrm{d}\mathbb{P}_X(x) \, \mathrm{d}\mathbb{P}_Y(y) \\
&= \int_{\mathbb{R}^p} g(x) \, \mathrm{d}\mathbb{P}_X(x) \int_{\mathbb{R}^q} h(y) \, \mathrm{d}\mathbb{P}_Y(y) \\
&= \mathbb{E}[g(H)]\mathbb{E}[h(y)].
\end{aligned}$$

(3) ⇒ (1) : Soit $A \in \mathcal{B}(\mathbb{R}^p)$ et $B \in \mathcal{B}(\mathbb{R}^q)$. Il suffit de prendre $g := \mathbb{1}_A$ et $h := \mathbb{1}_B$ pour obtenir l'indépendance. □

Proposition 3.3. Soit $(\Omega, \mathcal{F}, \mathbb{P})$ un espace probabilisable.
(1) Soit $X : \Omega \to \mathbb{R}^p$ et $Y : \Omega \to \mathbb{R}^q$ deux vecteurs aléatoires indépendants. Alors pour toutes fonction boréliennes f et g, $f(X)$ et $g(Y)$ sont indépendants.
(2) Soit $X_1, \dots, X_m : \Omega \to \mathbb{R}^{d_i}$ des vecteurs aléatoires indépendants. Alors pour tout $1 \le n < m$, $(X_1, \dots, X_n)$ et $(X_{n+1}, \dots, X_m)$ sont indépendants.

Démonstration.

(1) Soit f et g deux fonctions boréliennes. Alors il suffit d'appliquer le point (3) du Lemme 3.2 aux compositions de f et g avec des fonctions boréliennes positives pour obtenir l'indépendance de $f(X)$ et $g(Y)$.

(2) Soit $1 \leq n < m$. Alors il suffit d'appliquer le point (2) du Lemme 3.2 pour obtenir l'indépendance de $(X_1, \ldots, X_n)$ et $(X_{n+1}, \ldots, X_m)$.

$\square$

3.1.1. Critère d'indépendance pour des vecteurs discrets

Proposition 3.4. Soit $(\Omega, \mathcal{F}, \mathbb{P})$ un espace probabilisable, et $X : \Omega \to \mathbb{R}^p$ et $Y : \Omega \to \mathbb{R}^q$ deux vecteurs aléatoires discrets. Alors s'ils existent des fonctions $f : \mathcal{V}_X \to \mathbb{R}_+$ et $g : \mathcal{V}_Y \to \mathbb{R}_+$ telles que

$$\forall (x, y) \in \mathcal{V}_X \times \mathcal{V}_Y, \mathbb{P}(X = x, Y = y) = f(x)g(y)$$

alors X et Y sont indépendants, et il existe $c > 0$ tel que

$$\mathbb{P}_X(\{x\}) = cf(x) \text{ et } \mathbb{P}_Y(\{y\}) = \frac{1}{c}g(y).$$

Démonstration. Soit $A \in \mathcal{B}(\mathbb{R}^q)$ et $B \in \mathcal{B}(\mathbb{R}^q)$ alors

$$\begin{aligned}
\mathbb{P}(X \in A, Y \in B) &= \sum_{x \in \mathcal{V}_X \cap A} \sum_{y \in \mathcal{V}_Y \cap B} P(X = x, Y = y) \\
&= \sum_{x \in \mathcal{V}_X \cap A} \sum_{y \in \mathcal{V}_Y \cap B} f(x)g(y) \\
&= \sum_{x \in \mathcal{V}_X \cap A} f(x) \sum_{y \in \mathcal{V}_Y \cap B} g(y)
\end{aligned}$$

en particulier si on pose $B := \mathbb{R}^q$ et $c := \sum_{y \in \mathcal{V}_Y \cap B} g(y)$, on trouve

$$\mathbb{P}_X(A) = \mathbb{P}(X \in A, Y \in \mathbb{R}^q) = c \sum_{x \in \mathcal{V}_X \cap A} f(x)$$

d'où pour tout $x \in \mathcal{V}_X, \mathbb{P}_X(\{x\}) = cf(x)$. On fait la même chose avec $A := \mathbb{R}^p$ et $d := \sum_{x \in \mathcal{V}_X \cap A} f(x)$. Mais $\mathbb{P}(X \in \mathbb{R}^p, Y \in \mathbb{R}^q) = c \times d = 1$, donc $d = \frac{1}{c}$. Enfin

$$\begin{aligned}
\mathbb{P}(X \in a, Y \in B) &= \sum_{x \in \mathcal{V}_X \cap A} \mathbb{P}(X = x) \sum_{y \in \mathcal{V}_Y \cap B} \mathbb{P}(Y = y) \\
&= \mathbb{P}(X \in A)\mathbb{P}(X \in B)
\end{aligned}$$

donc X et Y sont indépendants.

$\square$

3.1.2. Critère d'indépendance pour des vecteurs à densité

Proposition 3.5. Soit $(\Omega, \mathcal{F}, \mathbb{P})$ un espace probabilisable, et $X : \Omega \to \mathbb{R}^p$ et $Y : \Omega \to \mathbb{R}^q$ deux vecteurs aléatoires à densités respectives f_X et f_Y.

(1) Si X et Y sont indépendantes. Alors le vecteur (X, Y) admet une densité f vérifiant :

$$\forall (x, y) \in \mathbb{R}^p \times \mathbb{R}^q, f(x, y) = f_X(x) f_Y(y)$$

(2) Si (X, Y) admet une densité f de la forme :

$$\forall (x, y) \in \mathbb{R}^p \times \mathbb{R}^q, f(x, y) = g(x) h(y)$$

où g et h sont boréliennes. Alors X et Y sont indépendantes et il existe $c > 0$ tel que

$$f_X = cg \text{ et } f_Y = ch.$$

Démonstration.

(1) Supposons que X et Y sont indépendantes. Soit $\varphi : \mathbb{R}^{p+q} \to \mathbb{R}_+$ une fonction borélienne, alors par la formule de transfert

$$\mathbb{E}[\varphi(X, Y)] = \int_{\mathbb{R}^{p+q}} \varphi(x, y) \, \mathrm{d}\mathbb{P}_{(X,Y)}(x, y)$$

puisque X et Y sont indépendantes on a

$$\begin{aligned}
\mathbb{E}[\varphi(X, Y)] &= \int_{\mathbb{R}^p \times \mathbb{R}^q} \varphi(x, y) \, \mathrm{d}\mathbb{P}_X(x) \otimes \mathbb{P}_Y(y) \\
&= \int_{\mathbb{R}^q} \int_{\mathbb{R}^p} \varphi(x, y) \, \mathrm{d}\mathbb{P}_X(x) \, \mathrm{d}\mathbb{P}_Y(y)
\end{aligned}$$

et puisque X et Y admettent des densités

$$\begin{aligned}
\mathbb{E}[\varphi(X, Y)] &= \int_{\mathbb{R}^q} \int_{\mathbb{R}^p} \varphi(x, y) f_X(x) \, \mathrm{d}\lambda(x) f_Y(y) \, \mathrm{d}\lambda(y) \\
&= \int_{\mathbb{R}^{p+q}} \varphi(x, y) f_X(x) f_Y(y) \, \mathrm{d}\lambda(x, y).
\end{aligned}$$

Donc (X, Y) admet bien une densité $(x, y) \mapsto f_X(x) f_Y(y)$.

(2) La réciproque se montre une nouvelle fois en appliquant le théorème de Fubini

□

3.2. Somme de variables aléatoires indépendantes

3.2.1. Cas de variables aléatoires discrètes

Proposition 3.6. Soit $(\Omega, \mathcal{F}, \mathbb{P})$ un espace probabilisable, et $X, Y : \Omega \to \mathbb{N}$ deux variables aléatoires discrètes indépendantes à valeurs entières. On pose $S := X + Y$. Alors on a

$$\forall n \in \mathbb{N}, \mathbb{P}(S = n) = \sum_{k \in \mathbb{N}} \mathbb{P}(X = k) P(Y = n - k)$$

3.2.2. Cas de variables aléatoires à densité

Proposition 3.7. Soit $(\Omega, \mathcal{F}, \mathbb{P})$ un espace probabilisable, et $X, Y : \Omega \to \mathbb{R}$ deux variables aléatoires à densités respectives f_X et f_Y. On pose $S \coloneqq X + Y$. Alors la densité de S est donnée par

$$\forall t \in \mathbb{R}, f(t) \coloneqq \int_{\mathbb{R}} f_X(x) f_Y(t - x) \, \mathrm{d}\lambda(x).$$